



EDA 2 2026.1 T01

Grupo 11 (Tema D)

Detecção de tópicos

Transformando dados em estratégia de negócio



O problema

Nossa equipe foi contratada por um resort de esportes que oferece todas as modalidades olímpicas aos seus hóspedes.

Nossa tarefa é organizar o site deles em áreas de interesse / categorias de esportes.



A entrada de dados




Coletamos a descrição dos esportes olímpicos da wikipédia e usamos a biblioteca spaCy (Python) para buscar as palavras chaves das descrições.

Solução

Luís Felipe, Rafael

Usando o json criamos grafos ponderados

Peso = características em comum



1. Renato, 2. Luís Felipe, 3. Rafael, 4. João Pedro, Vinícius (integração e revisão)

Montagem do grafo

- 1 Hash para interpretar JSON
 - 2 Modelagem do grafo
 - 3 Heap para auxiliar no kruskal
 - 4 Cortes para formar comunidades
- Comunidades = grafo esparso
Usamos listas de adjacência e
Kruskal





Resultados

Dificuldade em determinar:
LIMAR_PESO_COMUNIDADE


Se colocássemos 1 todos os esportes
fariam parte da mesma comunidade

Qualquer outro valor os esportes ficavam
sozinhos ou tinha um grupo imenso e o
resto sozinho



Grafo Final

A partir de dados extraídos da Wikipedia para cada um dos 75 esportes olímpicos, foi construído inicialmente um grafo bipartido com 391 vértices — 75 esportes e 316 características únicas — conectados por 1.077 arestas. Em seguida, esse grafo foi projetado em uma rede de 75 vértices, onde dois esportes são diretamente conectados por uma aresta cujo peso representa a quantidade de características que eles têm em comum.



```
Arquivo: data\webscraper_padronizado.json
Esportes: 75
Características únicas: 316
Vertices totais: 391
Associacoes esporte-caracteristica: 1077
Grafo construido com sucesso!
Associacoes mais frequentes na wikipedia:
Skate - skate: 17
Rugby Sevens - rugby: 11
Tiro Esportivo - tiro: 10
Karate - arte: 10
Hóquei no gelo - gelo: 10
```

Árvore Geradora Máxima

Sobre o grafo, foi construída uma Árvore Geradora Máxima (MST), que seleciona apenas as conexões mais fortes entre os nós, eliminando redundâncias e revelando o "esqueleto" das relações. Esse passo prioriza as associações mais representativas — por exemplo, as cinco mais frequentes na Wikipedia foram skate, rugby, tiro, arte marcial e gelo — indicando quais termos mais definem seus respectivos esportes.

```
Arvore Geradora Maxima construida com sucesso!
```


```
Comparacao esporte-esporte: minimo de 3 caracteristicas em comum (resgate de isolados com 2).
```

```
Comunidades detectadas: 18
```



Comunidades

Com critério mínimo de 3 características em comum para agrupar dois esportes (com resgate de pares isolados a partir de 2), o algoritmo identificou 18 comunidades. Cada comunidade reúne esportes que a Wikipedia descreve com um vocabulário semelhante, o que equivale a dizer que compartilham elementos estruturais, físicos ou de contexto.


Vinícius e Rafael



Visualização das Comunidades no MST



Grafo antes da Poda...



Vinícius e Rafael




Uma Observação interessante



Uma comunidade merece destaque pela sua inesperada coesão: Curling e Tiro Esportivo foram agrupados juntos por compartilharem os descritores alvo e pontuação por precisão. Apesar de serem esportes superficialmente muito distintos, a Wikipedia os caracteriza com o mesmo vocabulário funcional, o que demonstra a capacidade do método de capturar semelhanças não óbvias.




Luís Felipe e Rafael



Uso de LLM no Projeto

O uso de LLM no projeto consistiu na limpeza dos dados brutos do Wikipedia para uma organização de palavras repetidas mas de forma diferentes, como: chutar, chutou, chutaram para uma única como chutar só que citava 3 vezes para não perder contagem. Além de apoio na hora de codar, sempre usando como modo chat e tira dúvidas, nunca como criador do código sem visualização e monitoramento humano do que está escrito!



Conclusão

Dados textuais da Wikipedia, combinados com análise de grafos, agruparam os esportes olímpicos de forma coerente e totalmente automatizada. Das 18 comunidades, a grande maioria corresponde a categorias intuitivamente corretas, validando tanto os dados extraídos quanto o algoritmo. O caso Curling–Tiro evidencia a capacidade do método de revelar afinidades funcionais latentes entre esportes aparentemente distantes.



Obrigado pela Atenção

Foi um projeto de muito aprendizado

Grupo 11 - Tema D - EDA2 T01 2026.01

FCTE/ UnB

